

Tópicos de Inferência Causal*

Tiago C A Amorim (RA: 100675)^a

^aDoutorando no Departamento de Engenharia de Petróleo da Faculdade de Engenharia Mecânica, UNICAMP, Campinas, SP, Brasil

Keywords: Inferência Causal, Controle Negativo

1. Introdução

Este relatório é um resumo de dois artigos na área de inferência causal. O primeiro artigo tem um enfoque mais geralista, e aborda diversos assuntos da área [1]. O segundo artigo foca em controles negativos¹ [2]. Na medida do possível este resumo buscará seguir a notação utilizada ao longo do curso de inferência causal, que segue o livro de Peng Ding [3].

2. Causal Inference in the Social Sciences

Este artigo discute diversos assuntos ligados à avaliação de inferência causal. Será dado maior enfoque às novas técnicas e discussões trazidas pelo autor no lugar de descrever as metodologias já vistas durante a disciplina MI628: Inferência Causal.

2.1. Estudos Experimentais Randomizados

O autor cita que estudos experimentais randomizados surgem nos anos de 1920, com Fisher e Neyman. Apesar destas ferramentas ainda serem utilizadas, novas ferramentas foram desenvolvidas. O autor cita que em geral o objetivo de um estudo de inferência causal está mais ligado ao resultado médio do tratamento (visão *neymaniana*) e sua magnitude.

A técnica de **experimentos adaptativos**² foi desenvolvida para tratar de cenários em que existe uma resposta rápida ao tratamento, existem diferentes tratamentos disponíveis, a atribuição das unidades é sequencial e cujo o objetivo é descobrir o *melhor* tratamento, e não a magnitude do seu efeito. O autor dá como exemplo a avaliação de qual é a melhor propaganda a ser veiculada online.

Em um estudo tradicional as unidades seriam alocadas de forma igual entre os diferentes tratamentos. São apresentadas duas técnicas de experimentos adaptativos que recalculam a probabilidade de atribuição das unidades aos tratamentos, em função dos resultados alcançados

até determinado momento. Uma técnica usa a probabilidade posterior de determinado tratamento ser o melhor como peso na sua atribuição. A segunda técnica usa o limite superior dos intervalos de confiança do sucesso de um tratamento: **UCB** (*upper confidence bounds*). A próxima unidade é atribuída o tratamento com o maior UCB. Em ambas abordagens é preciso cuidar do balanço entre exploração e exploração.

Problemas citados pelo autor: vies de inferência ao usar média dos resultados como estimador da esperança dos resultados, efeito de covariáveis na probabilidade de atribuição, respostas que variam com o tempo (estocacidade ou sazonalidade).

Uma outra situação que precisa de tratamento especial é quando as condições de não-interferência e consistência (valor estável de tratamento da unidade ou SUTVA³) não são atendidas. Quando existe a possibilidade de transbordamento ou interferência entre as unidades, a estratégia é definida em função do tipo de transbordamento. Uma estratégia é particionar a população em subgrupos, de forma a limitar os efeitos de transbordamento ao subgrupo. Outra estratégia é com o uso de grafos bipartidos e clusterização aleatória. O último exemplo dado pelo autor é quando duas ou mais populações estão associadas a tratamentos, e as variações de atribuição dos tratamentos nos pares (ou triplas, ...) de indivíduos ajuda a estimar os efeitos de transbordamento.

2.2. Estudos Observacionais sob Ignorabilidade

Em estudos observacionais, assumir que a atribuição de tratamento é basicamente independente (condição de **ignorabilidade** forte: $Z_i \perp (Y_i(0), Y_i(1)) \mid X_i$) leva à possibilidade de analisar os dados como se fossem de um experimento randomizado. Além disto é comum assumir que a probabilidade de atribuição (**propensity score**) é limitada longe de zero e um: $e(x) = pr(Z_i = 1 \mid X_i = x) \in (\delta, 1 - \delta)$, com $\delta > 0$ (**sobreposição**).

A estimativa do efeito médio do tratamento sob ignorabilidade pode ser feita com diferentes abordagens (com comentários do autor):

*Relatório como parte dos requisitos da disciplina MI628: Inferência Causal.

¹Tradução livre de *negative controls*.

²Tradução livre de *adaptive experiments*.

³Do inglês: *Stable Unit Treatment Value Assumption*.

- *Matching*: Estimador intuitivo, mas necessita de grande número de *matches* e sofre quando existe um número grande de covariáveis.
- Regressão dos estimadores: Pode ser difícil de construir bons estimadores quando a dimensão das covariáveis é muito grande.
- Estimadores com o *propensity score*: Pode ser utilizado como uma covariável escalar junto com *matching* ou regressão, ou usar seu inverso como peso na estimativa do efeito causal médio.
- Estimadores duplamente robustos: É a classe de estimadores atualmente sugerida na literatura, pois tem boas propriedades mesmo que os estimadores tenham baixa convergência.

Violações de sobreposição podem ser contornadas ignorando amostras que estão muito próximas de zero ou um, ou usando $h(x) = e(x)(1 - e(x))$ como peso no estimador do efeito causal médio.

A estimativa do efeito causal médio condicionado em covariáveis ($\tau(x) = E[Y_i(1) - Y_i(0) \mid X_i = x]$) é uma área de estudo mais recente. Segundo o autor nesta área existem bons resultados com métodos de aprendizado de máquina, como florestas de regressão e florestas aleatórias.

Por último o autor discorre sobre linhas de pesquisa que buscaram estimar o efeito de assumir ignorabilidade em aplicações onde esta não pode ser assumida exatamente. São citadas três abordagens:

- Assumir que não existe ignorabilidade e estimar limites para o efeito médio do tratamento. Esta abordagem pode levar a limites muito grandes.
- Assumir ignorabilidade, mas condicional a uma covariável não observada, que tem limitada associação com os resultados potenciais e a atribuição de tratamento.
- x

2.3. Estudos Observacionais sem Ignorabilidade

2.4. Combinação de Estudos Experimentais e Observacionais

3. Negative Controls: A Tool for Detecting Confounding and Bias in Observational Studies

É apresentado o conceito de controle negativo. Este mecanismo é utilizado em estudos de biologia experimental, e os autores argumentam que pode ser adaptado para experimentos observacionais e de outras áreas. Associações não-causais podem ser causadas por erro de medição, confusão e viés de seleção de indivíduos para a análise. O uso de controles negativos ajuda a verificar o risco de interpretação não-causal como causal.

A ideia principal do controle negativo é repetir o experimento que atestou efeito causal, mas de forma que o resultado esperado seja a hipótese nula, i.e., sem efeito causal. Vários controles negativos podem ser necessários, em função dos possíveis efeitos não-causais (variáveis de confusão não medidas). A observação de efeito causal no controle negativo é indicativo de que variáveis não medidas estão influenciando os resultados de interesse. Mecanismos de construção de experimentos de controle negativo citados pelos autores:

- Retirar um dos elementos essenciais ao mecanismo em avaliação: Testar hipótese de viés de disponibilidade com perguntas *placebo*, que já se sabe não ter relação com o mecanismo avaliado, em um questionário sobre alguma doença.
- Neutralizar o efeito do mecanismo: Avaliar saúde de pacientes que recebem doses ineficazes de algum medicamento.
- Testar com condições em que o mecanismo avaliado não funciona: Índice de hospitalizações por quebra de ossos em função de tomar ou não a vacina da gripe.

Em resumo, o propósito do controle negativo é de testar condições em que o mecanismo avaliado não está ativo, mas que podem sofrer dos mesmos vieses (medidos e não-medidos) do experimento original. Seguindo a Figura 1, uma resposta de controle negativo é uma resposta (**N**) que é influenciada pelos mesmos parâmetros que influenciam o tratamento (**Z**) e a resposta de interesse (**Y**). Se as variáveis de confusão não medidas (**U**) forem as mesmas para os pares **Z+Y** e **Z+N**, então **Y** e **N** são ditos *U-comparáveis*.

Assumindo que esta nova resposta (**N**) não é influenciada pelo tratamento (**Z**), e que a resposta de interesse (**Y**) e a nova resposta (**N**) são *U-comparáveis*, se não é observado efeito causal de **Z** em **N**, então podemos afirmar que **provavelmente** um efeito causal observado de **Z** em **Y** não é resultado de um viés desconhecido. Segundo os autores, na prática não é possível tecer uma afirmação estrita sobre a causalidade de **Z** em **Y** porque em geral **Y** e **N** são apenas aproximadamente *U-comparáveis*.

A mesma lógica pode ser aplicada para encontrar um tratamento de controle negativo (**B**). Se as variáveis de confusão não medidas (**U**) forem as mesmas para os pares **Z+Y** e **B+Y**, então **Z** e **B** são ditos *U-comparáveis*. Novamente, se não existe causalidade de **B** em **Y**, então uma causalidade observada de **Z** em **Y** provavelmente não é efeito de um viés desconhecido.

Os autores argumentam que é uma boa prática usar vários controles negativos para ajudar na validação de um estudo que apontou causalidade, e que conhecimento do assunto objeto do estudo é crucial para fazer boas escolhas de controles negativos.




Figura 1: Diagrama de causalidade: efeito do tratamento Z no resultado Y , com as variáveis de confusão X (medida) e U (não medida). A linha tracejada entre X e U indica que um pode influenciar o outro. Neste exemplo os resultados N e Y são ditos U -comparáveis. (Adapatado de [2])

4. Discussão

Referências

- [1] G. W. Imbens, Causal inference in the social sciences, Annual Review of Statistics and Its Application 11 (2024).
- [2] M. Lipsitch, E. T. Tchetgen, T. Cohen, Negative controls: a tool for detecting confounding and bias in observational studies, Epidemiology 21 (3) (2010) 383–388.
- [3] P. Ding, A first course in causal inference, arXiv preprint arXiv:2305.18793 (2023).